


# 薛旭阳

📞 18636867960 · ✉ 18636867960@163.com · 📧 微信号: xxy159357qaz

预计实习时长: 6 个月, 可立刻到岗



## 🎓 教育背景

2024.09 - 2027.06 | 华中科技大学 (985)

研二在读 (保研)

2020.09 - 2024.06 | 郑州大学 (211)

学士学位

华中科技大学学业奖学金一等奖、郑州大学优秀学生奖学金二等奖、全国大学生数学建模竞赛省级二等奖

参加 2025 腾讯游戏算法大赛: 数智决策科学赛道 (Agent/Text2SQL), 全国排名 TOP 60

参加 2025 腾讯广告算法大赛: 全模态生成式推荐赛道, 实战探索多模态 RAG 与生成式排序架构

## 🔧 专业技能

|             |                                                                             |
|-------------|-----------------------------------------------------------------------------|
| 编程语言        | 熟悉 Python (FastAPI/并发), Go (Eino), C++ (STL/Asio); 熟练应用常用设计模式               |
| Agent 与 RAG | 掌握 Agentic Workflow 开发与多级记忆管理; 熟练使用 LangChain/Dify/Eino; 熟悉 Milvus 与 RAG 优化 |
| 模型微调与 RL    | 熟悉 SFT 微调流程 (LoRA); 了解 RLHF/DPO/GRPO 等强化学习算法; 熟练掌握 vLLM/Ollama 高性能部署        |
| 后端与工程       | 熟悉 TCP/IP 网络编程; 掌握 MySQL (索引) 与 Redis (分布式锁/缓存); 熟练使用 Docker, Git, Linux    |

## 💼 实习经历

🌐 Moatable (原人人网) AI 后端开发实习生 · 🏢 Lofty AI 部门 2025.09 - 2026.01

- **业务背景**: 参与 Flow (Papago.ai) 智能体平台开发, 该平台通过为 Lofty、TruckerPath 等业务线提供核心 AI 引擎与运行时支持。负责 Flow Core (业务管理层) 与 Flow Agent (AI 执行层) 的开发, 涵盖业务逻辑、Agent 开发等多个方面
- **多模型集成与分布式记忆架构**: 开发 Model Adapter 层适配 Gemini 与 AWS Bedrock (Qwen) 模型, 实现全量功能接入; 利用 AsyncExitStack 实现连接池复用, 降低核心接口延迟 20%。研发 Cortex 记忆中枢, 支持单/多 Agent 间的记忆共享与逻辑隔离; 通过 MemoryBuffer 异步缓冲与 Redis + Lua 分布式锁, 优化长效记忆质量并解决高并发竞争问题
- **多智能体编排与治理**: 针对 Supervisor-Worker 模式开发无状态 Validator 提升参数准确率; 研发 Agent Overlap Analyzer, 利用 TF-IDF 量化职责重叠度以治理意图漂移; 开发 AgentSelector, 通过强制 Tool Calling 替代自然语言分类, 极大增强极端场景下的路由稳定性
- **工程效能与成本优化**: 开发端到端 LLM 自动化评估流水线, 支持 Batch API 与 断点续传 (Checkpoint) 机制, 使回归测试计算成本降低 50%; 落地 TOON 序列化协议与语义压缩技术, 显著降低线上全链路 Token 消耗
- **Lofty Agent Studio 平台开发**: 主导研发后端服务, 基于 AWS Cognito 与 Lambda 实现免密 SSO 鉴权与 Team 隔离; 设计并开发新的 Workspace 级别通用接口, 支撑 NLP 团队将用户自定义智能体动态接入现有业务流
- **技术栈**: Java (JDK 21), Python, Spring Boot, FastAPI, Redis, AWS (Lambda/ECS/Cognito), MySQL, DynamoDB

🏢 Momenta CPM 实习生 2025.02 - 2025.06

- 负责车型的 6 个小版本 冒烟测试与智驾功能联调, 构建测试用例验证功能, 确保数据闭环回流
- 独立完成上百台车辆的 ADC 软件 OTA 部署, 熟练运用 Linux/Shell 指令处理大规模车端任务
- 掌握车端设备 (IPC/IPD) 远程调试与 Docker 环境配置; 通过核心日志分析与标定文件管理, 精准诊断智驾功能故障, 支持自动驾驶路测迭代

## </> 项目经历

🔗 全栈即时通讯项目 个人项目 2025.03 - 2025.07

C++, Qt, Boost.Asio, gRPC, MySQL, Redis

分布式即时通讯系统, 采用 gRPC 微服务架构, 设计自定义应用层协议, 支持服务发现、断线重连与负载均衡, 支持登录注册, 好友管理、聊天通信、文件传输等核心功能

- 核心网络层基于 Boost.Asio 实现 Reactor 高并发模型, 采用 One Loop Per Thread 策略与 I/O Context 池, 单机压测消息延迟稳定在 10ms 以内, 单服务器支持 8000+ 稳定连接, 多服务器可支持 1W+ 活跃用户
- 构建分布式服务集群, GateServer 网关实现统一鉴权, StatusServer 采用一致性哈希 算法进行节点调度, 有效解决服务器扩容时的 会话迁移 与 雪崩问题
- 设计高可用数据存储方案, 封装 MySQL/Redis 连接池, 采用 Cache-Aside 模式与 延时双删 策略保障缓存一致性, 引入 gRPC 实现服务间的高效低延迟通信
- 基于 Qt 开发仿微信桌面客户端, 利用 信号槽机制 解耦 UI 与网络, 封装 TCP 粘包处理, 完整实现 用户登录、好友管理、断点续传 等业务模块

🧠 GigaEinoAI —— 个人知识库智能助手 个人项目 2025.07 - 2025.09

Go, Eino, Hertz, Milvus, MCP

基于 Go 语言开发的个人知识库智能助手, 集成 RAG 技术与 MCP 协议, 支持工具调用与长文本对话

- 基于 Eino 框架 编排大模型图模式, 利用 上下文压缩 与 前缀缓存 机制支持长上下文, 集成 MCP 实现联网搜索等工具调用
- 构建基于 Milvus 的 RAG 系统, 支持多格式文档解析; 通过 混合检索、并行检索与重排序 策略, 显著提升问答准确率
- 使用 Hertz 框架 构建高性能 HTTP 服务, 配置 CORS 中间件与流式响应接口, 实现低延迟的 AI 对话交互